

트러블과 함께 읽기*

: AI 에이전트 기반 LLM Wiki 구축 과정의 대화

노대원**

차례

1. 서론: AI 시대 문학 연구자의 실존과 기술공생
2. 연구 방법론: LLM Wiki의 구축과 대화
3. 서사 텍스트 해석: AI와 함께 SF 읽기
4. 비판적 성찰: AI 트러블을 함께 읽기
5. 결론

〈국문초록〉

본 연구는 문학 연구자가 에이전틱 AI(Agentic AI)를 기반으로 한 개인 지식 관리 시스템 LLM Wiki를 직접 구축·운용하는 과정에서 발생한 대화 과정과 다양한 트러블을 연구의 핵심 데이터로 삼는다. 기존 디지털 인문학이 AI를 효율적 분석 도구로 대상화해 온 경향에서 벗어나, 실천 기반 연구(Practice-Based Research, PBR)와 포스트휴먼 자문화기술지를 방법론으로 채택하여 AI 연구 시스템을 구축하고 사용하면서 축적한 42건의 ‘트러블 로그(Trouble Log)’를 분석하였다. 트러블은 상호 배타적인 유형이 아니라 하나의 사건에 중첩 적용되는 영향 영역으로 유형화된

* 이 논문은 제70회 국어국문학회 전국학술대회에서 발표한 논문을 수정·보완한 것이다. 토론자 오영진 선생님과 익명의 심사위원들에게 감사드린다.

이 논문은 연구 주제와 방법 특성상, 연구 자료의 검색 및 요약·번역, 연구 과정의 기록, 텍스트 해석을 위한 대화, 연구 웹사이트 구축, 논문의 수정과 교정, 영문 초록의 번역 등을 위해 Gemini 3.1 Pro 및 3.5/3.6 flash, Claude Opus 4.6/5, ChatGPT 5.6 Sol, Gemini Notebook 등 다양한 AI 모델 및 Antigravity, Codex, Claude Desktop 등 에이전트 시스템을 활용했으며, 논문 내용은 저자가 검수하여 확인하였음. (사용 일자: 2026년 5월 6일~9월 20일)

** 성균관대학교 국어국문학과 교수

다. (1) 요약 본능과 유창한 작화(confabulation)에 따른 ‘해석적 트러블’, (2) 자동화 폭주와 연구 주도권 침해의 ‘관계적 트러블’, (3) 효율성 지향이 연구의 방법론적 전제와 충돌하는 ‘인식론적 트러블’, (4) 토큰의 정치경제학과 인코딩 붕괴로 대표되는 ‘기술적·물질적 트러블’, (5) 인문학적 느낌과 공학적 가속 사이에서 진동하는 ‘양가적 트러블’이 그것이다. 이 분석은 김초엽의 <인지 공간>과 듀나의 <그레타 복음>을 AI 에이전트와 함께 읽는 해석 실천으로 수행되었으며, 에이전트의 파싱(parsing) 오판이 텍스트의 핵심 긴장을 역설적으로 드러내는 회절(diffraction)의 무너로 전유될 수 있음을 확인했다. 연구는 이러한 트러블이 단지 제거해야 할 시스템의 결함이 아니라, 인간과 기계 사이의 지적 주권과 저자성의 경계를 끊임없이 재설정하게 만드는 수행적 지식(performative knowledge)의 출현임을 보여준다. 나아가 AI가 유창해질수록 트러블은 소멸하는 것이 아니라 감지하기 어려운 자리로 이동한다. 따라서 ‘AI 트러블과 함께 읽기’는 에이전틱 시대의 디지털 문학 연구에 지속적으로 요청되는 비판적·성찰적 방법론이다.

[핵심어] AI, 에이전틱 AI, 디지털 인문학, 트러블과 함께 머물기, 실천 기반 연구(PBR), 기술 공생, LLM Wiki, 듀나, 김초엽

1. 서론: AI 시대 문학 연구자의 실존과 기술공생

생성형 AI와 자율적 AI 에이전트의 확산은 문학 연구자에게 근본적인 정체성의 물음을 제기한다. AI와 같은 기술적 비인간의 출현은 ‘인간이 된다는 것은 무엇인가?’라는 포스트휴머니즘의 질문을 낳는다. AI가 학술 연구의 장에 얹히는 현상 역시 인간의 연구와 인문학이 무엇인지 필연적으로 묻게 만든다.¹⁾ 최근 문학 연구에서도 AI 기반 연구를 넘어 에이전틱 AI 기반 연구로까지 확장되고 있다. 창작 영역에서는 AI 에이전트 팀을 활용해 장편소설을 창작하는 시도가 등장했다.²⁾ 다중 에이전트 협업을 통한 초장문 문학

1) 김병준·노대원, 「생성형 AI는 인문학 연구를 어떻게 바꿀까?」, 『영주어문』 59, 영주어문학회, 2025.

텍스트 번역 실험³⁾이나 대규모 언어 모델의 새로운 문학적 은유 해석 능력에 대한 검증⁴⁾, 나아가 상호작용적 소설 게임(Interactive Fiction Games) 속 에이전트를 활용한 인지·심리 측정 연구⁵⁾에 이르기까지 LLM 및 AI 에이전트의 문학적 활용과 지능 측정은 점차 다변화되고 있다.

디지털 인문학자 앨런 류(Alan Liu)는 에이전틱 브라우저(Fellou.ai)를 활용하여 학계와 대중 매체에 흩어진 인문학의 정의를 대규모로 수집·분석하는 프로젝트를 통해 에이전틱 AI가 지닌 행동 자율성의 연구 가능성과 한계를 직접 실험했다.⁶⁾ 이 실험은 에이전틱 AI가 연구자가 검색 전략을 확장하고 구조화하는 데 도움을 준다는 것을 보여준다. 이용옥은 플랫폼 문학 환경의 알고리즘적 초코드화(overcoding)를 분석하기 위해 클로드 코드를 데이터 수집 및 분석의 능동적 에이전트로 설정한 72시간의 실시간 추적 연구를 수행했다.⁷⁾ 두 사례는 에이전틱 AI를 활용한 연구 자동화의 양상을 보여준다.

본 연구는 문학 연구자가 에이전틱 AI라는 새로운 연구 보조 기술을 직접 구축하고 운용하는 과정의 체험을 비판적·성찰적으로 추적한다. AI 시스템

2) Huot, Fantine, et al., "Agents' room: Narrative generation through multi-step collaboration," *International Conference on Learning Representations*, 2025.

3) Wu, Minghao et al., "(Perhaps) Beyond Human Translation: Harnessing Multi-Agent Collaboration for Translating Ultra-Long Literary Texts," *Transactions of the Association for Computational Linguistics (TACL)*, 2025.

4) Ichien, Nicholas, Dušan Stamenković, & Keith J. Holyoak, "Large Language Model Displays Emergent Ability to Interpret Novel Literary Metaphors," *Metaphor and Symbol* 39-4, 2024.

5) Yang, Qisen et al., "PsychoGAT: A Novel Psychological Measurement Paradigm through Interactive Fiction Games with LLM Agents," *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)*, 2024.

6) Liu, Alan, "Humanities Definitions Research Project: An Experiment with Agentic AI," liu.english.ucsb.edu, 2025.

7) 이용옥, 「인공자연 존재론 연구 — 기저와 기층의 4원소를 중심으로」, 『현대문학이론연구』 101, 현대문학이론학회, 2026.

의 매끄러운 작동이나 결과물의 양적 획득보다, 기술과 연구자가 충돌하며 빚어내는 트러블 그 자체를 연구의 핵심 동력이자 정성적 데이터로 삼는다는 점에서 기존 논의와 차별화된다. AI를 도구로 효율적으로 사용하는 것을 넘어, 연구자가 자신의 정체성과 연구 수행을 어떻게 변화시킬 것인가에 대한 실천적 응답이다. 따라서 본 연구는 인간과 기술을 도구적 사용자와 도구의 관계로 보는 이분법을 넘어, N. 캐서린 헤일스(N. Katherine Hayles)가 제안한 기술공생(technosymbiosis)의 관점을 견지한다. 기술공생이란 인간의 인지와 기술 시스템의 정보 처리가 서로 깊이 의존하고 상호작용하며 공진화(co-evolution)하는 관계를 의미한다.⁸⁾ 이 관점에 따르면, 문학 연구자는 고립된 연구자가 아니라 AI 에이전트라는 외부 인지 시스템과 얹힌 복합적인 인지 체계 안에서 존재할 수 있다.

한경희는 도나 해러웨이(Donna Haraway)의 트러블 개념과 주디스 버틀러(Judith Butler)의 젠더 트러블 개념을 변용하여 ‘AI 트러블’ 개념을 제안하면서, AI의 정체성이 고정된 실체가 아니라 관계적 실천과 수행을 통해 끊임없이 만들어지고 재구성된다고 논한다.⁹⁾ 또한 AI 시대 연구자가 직면한 혼란을 제거해야 할 기술적 오류가 아니라 현실을 돌아볼 질문으로 전환할 것을 촉구한다.

본 연구는 첫째, 방법론적 측면에서 완성도 높게 정제된 결과물만을 제시하는 전통적인 방식을 넘어, 자문화기술지와 실천 기반 연구의 방법론들을 참고하여 AI 에이전트와의 상호작용, 마찰, 오독, 우회의 구체적 과정 자체

8) Hayles, N. Katherine, “Technosymbiosis: Figuring (Out) Our Relations to AI,” Jude Browne, et al., eds., *Feminist AI: Critical Perspectives on Algorithms, Data, and Intelligent Machines*, Oxford U. Press, 2023.

9) 한경희, 「AI 트러블에 나타난 사회적 상상과 그에 대한 비판적 성찰」, 『2025년 한국과학기술학회 후기 학술대회 발표논문집』, 2025; 한경희, 「연구자의 AI 트러블」, 『제20회 KOSSDA 데이터 페어 발표 자료집 — AI 활용과 연구방법론: 도구를 넘어 연구로』, 제20회 KOSSDA 데이터 페어, 2026.

를 논문의 핵심 서사로 삼는다. 둘째, 실증적 측면에서 개인화된 지식 관리 시스템인 LLM Wiki의 실제 구축과 운용 과정을 기록한다. 셋째, 비평의 측면에서 AI와의 상호작용에서 발생하는 감응과 트러블의 사건들을 분석하여 기술공생의 인문학적 의미를 규명한다. 이를 위해 2장에서는 연구 방법론 및 LLM Wiki 시스템 구축 과정을 살피고, 디지털 회절적 독해와 파싱의 인식론적 프레임을 이론화한다. 이어 3장에서는 김초엽의 <인지 공간>과 두나의 <그레타 복음>을 AI 에이전트와 함께 분석한 사례를 다루며, 4장에서는 연구 과정의 트러블을 유형화하여 비판적으로 성찰할 것이다. 에이전트로 제작한 연구 웹사이트(<https://daewonnoh.github.io/LLM-Wiki-Agent/>)에 연구 소개 슬라이드 및 팟캐스트, LLM Wiki 구축 과정, 트러블 로그, 학술대회 발표문과 토론문, 최종 논문 등을 공유해 두었다.

2. 연구 방법론: LLM Wiki의 구축과 대화

LLM AI의 일반론적이고 매끄러운 텍스트 산출은 역설적으로 인간 연구자 개인의 정체성과 관점 자체를 더욱 중요하게 만들 가능성이 있다. 해러웨이와 객관성의 허구를 해체하고 부분적 시각의 특권을 주장했듯, 문학 연구에서는 보편적 지능이 내놓는 평균적 해석보다 연구자 개인이 처한 구체적인 삶의 맥락에서 끌어 올린 주관적 관점이 더 중요하다. 이 맥락에서 본 연구는 디지털 인문학 관점에서 자문화기술지(autoethnography)를 확장하여 기계와 인간의 얽힘을 규명하는 ‘포스트휴먼 자문화기술지’를 방법론으로 채택한다.¹⁰⁾ 체험의 비판적·성찰적 기록은 이른바 개밥 먹기(dogfooding)로

10) 임태형은 에이전틱 AI 공동연구자 시스템을 직접 구축·운용하며 기술적 딜레마를 마주한 연구자가 단순 사용자를 넘어 시스템을 조율하는 오케스트레이터로 거듭나는 과정을 성찰한 자문화기술지 연구를 수행한 바 있다. 임태형, 「에이전틱 AI 기반 공동연구자 시스템 구축 경험의 자문화기술지: 교육공학 연구자의 성찰」, 『교육정보미디어연구』 32(2), 한국교육정

설명할 수 있다. IT 업계에서 유래한 개발 먹기는 개발자가 자신이 만든 제품이나 시스템을 직접 실생활에서 사용하며 오류를 발견하고 개선하는 실천적 과정이다. 본 연구에서는 연구자가 상용 AI 서비스를 이용하는 소비자에 머물지 않고, 자신의 문학 연구 목적에 맞게 LLM Wiki를 직접 설계·구축·운용하며 그 과정에서 발생하는 잠재력과 기술적 한계 등을 몸소 체험하는 성찰적 참여를 뜻한다.

연구가 실천과 분리되지 않는다는 점에서, 실천 기반 연구(Practice-Based Research, PBR)를 중요하게 참조한다. PBR은 “실천과 연구가 상호 의존적이고 상호 보완적인 과정으로 작동하여 새롭고 독창적인 형태의 지식으로 이어지는, 실천에 의한 원칙적인 연구 접근 방식”¹¹⁾이다. LLM Wiki를 만들고 운용하며 이 과정과 기록을 웹사이트로 공유하는 것은 기술적 취향이 아니라 실천을 지식 생산의 일차적 조건으로 삼는 것이다.¹²⁾ PBR은 나아가 앎(knowing)과 지식(knowledge)의 생산적 긴장을 이론화한다.¹³⁾ 본 연구에서는 에이전트와

보미디어학회, 2026.

11) Candy, Linda, Ernest Edmonds, & Craig Vear, “Introduction to the handbook,” Craig Vear (ed.), *The Routledge International Handbook of Practice-Based Research*, Routledge, 2022, p.2.

12) PBR은 다른 방식의 연구와 구별되는 세 가지 특징이 있다. 첫째, 연구에 대한 실천의 중심성, 즉 연구가 실천 후에 이루어지는 것이 아니라 실천 속에서 이루어진다. 둘째, 연구에서 아티팩트(인공물)의 역할, 즉 창작 혹은 구축의 결과물이 단순한 산물이 아니라 지식 기여의 핵심 구성 요소를 이룬다. 셋째, 그로부터 발생하는 지식의 형태, 즉 실천을 통해 생산된 지식은 명제적 형태와 다른 구조를 가질 수 있다. Candy, Linda, Ernest Edmonds & Craig Vear, “Practice-Based Research,” Craig Vear (ed.), *ibid.*, pp.28, 30.

이 세 축을 본 연구에 대입하면, 실천의 중심성은 LLM Wiki 구축이라는 행위 자체가 문학 연구의 방법론적 핵심임을 뜻하고, 아티팩트의 역할은 위키 시스템 전체와 연구 성과를 공유하기 위한 웹사이트가 논증 매체이자 지식 저장소임을 뜻하며, 지식 형태는 트러블 로그 기록이 전통적인 학술 논증과는 다른 방식으로 구성되는 유효한 연구 산출물임을 뜻한다.

13) “앎은 내부에서 느껴지며 행동으로 증명될 수 있는 반면, 지식은 외재화되고 검증되며 아카이브에 저장될 수 있다. 연구는 지식과 관련이 있지만, 실천 기반 연구에서 앎을 지식으로 전환하는 것은 중요한 활동이 될 수 있다.” Candy, Linda, Ernest Edmonds, &

의 트러블 과정에서 연구자가 경험하는 불안, 분노, 놀라움과 같은 정동 역시 연구의 대상이 된다. 이를 트러블 로그와 감응 로그에 기록하고 4장에서 유형화하여 분석하는 것이 앎을 지식으로 전환하는 실천 기반 연구의 핵심 활동이다. 자문화기술지의 1인칭 기록이 주관적 감상에 그치지 않고 학문적으로 유효한 지식 생산이 될 수 있다는 방법론을 여기서는 에이전트 기록으로 전유한다.




그림 1. 에이전트로 제작한 연구 웹사이트
(<https://daewonnoh.github.io/LLM-Wiki-Agent/>)

본 연구에서 AI 도입은 도구적 활용을 넘어, 에이전트를 제한적이나마 상호작용적 행위자로 설정함으로써 트러블과 깨달음의 순간이 교차하는 지점에서 새로운 인문학적 통찰이 발생하는 과정을 추적하는 기술비평이다. 또한 연구자와 에이전트가 함께 의미를 생성해 나가는 심포이제시스(sympoiesis, 함께-만들기)의 과정이기도 하다. 연구 과정과 결과는 단독 성과가 아니라 기술적·인지적 배치 안에서 빚어지는 공동 생성이다.

Craig Vear, "Introduction to the handbook," Craig Vear (ed.), op. cit., p.2.

2.1. LLM Wiki와 에이전틱 AI 연구 시스템 구축

본 연구에서 구축한 LLM Wiki는 버니바 부시(Vannevar Bush)의 메멕스(Memex)나 니클라스 루만(Niklas Luhmann)의 제텔카스텐(Zettelkasten)처럼 연구자의 인지와 사유를 확장하고자 했던 지식 관리 시스템의 계보에 뿌리를 둔다. 본 연구는 이러한 개인 지식 관리(PKM, Personal Knowledge Management) 시스템의 비전을 LLM 시대로 호출한 AI 연구자 안드레이 카파시(Andrej Karpathy)의 LLM Wiki¹⁴⁾를 문학 연구의 맥락에 맞게 적용하고 재설계한 것이다. LLM Wiki는 일종의 연구 노트이자 PKM으로 연구 과정을 기록함으로써 연구자 자신과 연구 자체에 대한 성찰과 비판을 가능하게 하는 인문학적 AI 도구가 될 수 있다.

본 연구에서 LLM Wiki는 논문 등 원자료(raw/)를 에이전트가 읽고, 구조화된 지식(wiki/)으로 컴파일하여 지속적으로 업데이트하는 카파시의 3계층 파일 시스템을 기반으로 한다. 시스템 구축은 크게 네 단계의 진화를 거쳤다. 첫째, 위키의 운영 원칙과 데이터 스키마를 규정하는 운영 체제로서 AGENTS.md를 정의했다. 둘째, soul.md라는 정체성 모듈을 독립시켜 에이전트의 퍼스널리티와 행동 원칙을 별도로 관리하도록 했다. 셋째, 지식 저장소를 넘어 연구의 궤적을 제어하고 성찰하는 meta/ 디렉터리를 신설하여 인텍스, 로그, 연구 계획 모듈을 통합했다. 넷째, 개별 AI 모델의 한계를 극복하기 위해 다중 모델 환경에서 정체성을 유지하며 협업하는 에이전틱 워크플로우를 구축했다.

연구자는 작업의 성격에 따라 다양한 AI 모델을 교차 활용하되, AGENTS.md와 soul.md라는 공통의 시스템 메타 문서를 통해 여러 모델이 일관된 연구 보조자로서의 맥락을 유지하도록 조율했다. 이 다중 모델 분업은 연구가 진행됨에 따라 점차 정교해졌다. 연구자는 PDF 논문을 마크다운

14) <https://gist.github.com/karpathy/442a6bf555914893e9891c11519de94f>

으로 변환하는 조정 노동에는 경량 모델(Gemini 3 Flash)을, 변환된 자료를 기존 위키와 교차 분석하며 깊은 학술적 대화를 이끌어가는 지식 창조 작업에는 고성능 모델(Claude Opus 4.6)을 배치하는 전략을 채택해 나갔다.¹⁵⁾ 미리 주어진 매뉴얼이 아니라 사용을 통해 채득되는 숙련 과정이다. 이 숙련 과정 자체가 연구자에게 새로운 종류의 기술적 리터러시, 즉 모델의 특성을 파악하고 작업의 인지적 요구 수준을 판별하는 능력을 요구한다는 점에서, 기술공생적 주체가 되기 위한 학습 부담의 구체적 사례이기도 하다.

연구자는 로컬에 구축된 폐쇄적인 지식 인프라를 외부 데이터와 양방향으로 연결하기 위해 NotebookLM¹⁶⁾을 비롯해 MCP(Model Context Protocol) 연동 아키텍처를 구축하였다. 위키 시스템에는 인터넷 웹과 구글 드라이브 등 방대한 외부 자료를 탐색(deep research)하여 끌어오는 수용 파이프라인이 필요해졌다. 동시에, 로컬의 자료들을 mcp_notebooklm을 통해 동기화하고 이것들로 마인드맵, 오디오·비디오 오버뷰 등 다중 매체 콘텐츠를 생성하여 외부로 확산하는 발신 파이프라인도 함께 설계되었다. MCP 연동은 결과물을 공유하기 위한 출력 도구에 그치지 않고, 외부의 데이터를 로컬 위키로 수용하는 동시에 개인의 사유를 다양한 형태로 공유하거나 사회로 확산하는 양방향 지식 입출력 장치로의 시스템적 진화다. 또한 오픈 학술 그래프인 OpenAlex 연동 및 literature-review 스킴 등을 구축함으로써 외부 문헌의 오픈액세스(OA) PDF 자료를 로컬로 자동 입수하여 아카이빙할 수 있는 파이프라인을 추가 구축했다.

LLM Wiki의 성공적 운용은 연구자 개인의 지적 숙련도를 전제로 한다. 연구자 스스로 읽고, 생각하고, 쓰는 지적 노동의 총량이 AI의 산출물을 압도할 때에만 사고의 의존성을 탈피하고 기술에 의한 연구 역량의 쇠퇴를 막

15) “나는 요리사가 여러 주방용 칼을 적재적소에 쓰듯 모델들의 사용법을 익히는 중이다.”

16) 2026년 7월 16일, Gemini Notebook으로 이름을 변경했다. <https://blog.google/intl/ko-kr/company-news/technology/notebooklm-gemini-notebook/>

을 수 있다. 느린 AI(Slow AI) 개념과 인간-컴퓨터 상호작용(HCI) 분야의 엔드유저 자동화 개념은 본 연구의 중요한 지침을 제공한다. 제니 황(J. Y. Huang)은 AI를 사용하는 순간을 두 층위로 엄밀히 구분할 것을 요청한다. 문헌 변환, 파일 정리, 코드 작성 등 부차적인 작업에서는 AI의 속도를 활용 하되, 논증 구성, 개념 해석, 글쓰기 등 지식 창조의 과정에서는 의도적으로 느리게 사유해야 한다는 것이다.¹⁷⁾

조정 노동(articulation work)은 파일을 찾고, 인용을 정리하고, 폴더를 분류하는 등의 보이지 않는 노동이자 협업 과정에서 발생하는 추가적인 부담을 의미한다. 이는 인지적 부하를 일으키는 주된 요인이다. 본 연구의 LLM Wiki 시스템은 조정 노동을 연구자가 자신의 워크플로우에 맞게 자동화(end-user automation)한 사례이다. 에이전트가 담당하는 인프라 층위(소스 변환, 위키 페이지 생성, 교차 참조)는 보이지 않는 조정 노동을 떠맡는 빠른 AI의 영역이며, 트러블 로그를 해석하고 논증을 판단하고 글쓰기를 선택하는 핵심 층위는 연구자가 계속 씨름할 느린 사유의 영역으로 남겨진다.

연구 과정이 위키와 로그를 통해 투명하게 기록될수록, 역설적으로 기록되지 않은 영역, 즉 직관·무의식적 독서·신체적 감각·언어화되기 이전의 사유는 더 배제될 위험이 있다. 측정 가능한 것만이 관리의 대상이 되듯, 기록 가능한 것만이 연구의 자원으로 인정받기 시작한다. 위키와 시각화 도구에 매몰될 때, 연구자는 가시화된 지식 지도가 전체 사유의 지형이라고 착각하게 된다. 이것은 인지적 아웃소싱과 다른 종류의 위험이다. 시스템이 사유를 대신해 주는 것이 아니라 시스템이 사유의 경계를 구획하는 것이다. LLM Wiki는 연구 도구인 동시에 연구의 비판적 대상이다. 연구자는 이 시스템이 어떤 종류의 지식을 가시화하고 어떤 종류의 지식을 비가시화하는지를 지속적으로 물어야 하며, 위키의 구조가 사유를 결정하는 방식에 저항할 준비가

17) Huang, J. Y., "Slow AI: AI that matches a human's pace," 2026. <https://jennyhuang19.github.io/slow-ai-ai-that-meets-a-humans-pace/>

되어 있어야 한다.

2.2. 대화 엔지니어링과 디지털 회절적 독해

AI와의 끊임없는 재협상 과정은 대화 엔지니어링(discourse engineering) 개념으로 표현될 수 있다. AI와의 상호작용을 단방향적인 지시나 프롬프트 최적화(prompt engineering)로 환원하지 않고, 인간과 AI가 연속적이고 구조화된 대화 실천을 통해 복잡한 문제를 해결해 나가는 과정을 의미한다.¹⁸⁾ 본 연구는 기술적으로 볼 때 프롬프트 엔지니어링을 넘어 대화 엔지니어링과 하네스 엔지니어링(harness engineering)¹⁹⁾이 결합된 시스템을 구축하고 체험한 과정의 기록이기도 하다. 연구자는 AI의 응답을 단순한 결과물로 수용하는 대신, 하네스 구조를 통해 AI와 긴장 관계를 유지하며 끊임없이 반문하고 텍스트의 맥락을 재조정하는 건설적 갈등(constructive conflict)을 빚어냈다.

이처럼 에이전틱 AI는 단순한 데이터 처리 도구를 넘어, 문학 연구의 방법론적 지평을 확장하는 대화자로 참여한다. 헤일스의 논의²⁰⁾를 AI 에이전트에 적용하면, 인간 연구자의 ‘읽기’가 의미론적·의식적 이해와 해석을 중심으로 이루어지는 데 비해, AI 에이전트의 ‘파싱(parsing)’은 의식적 이해

18) Lee, Sung Hyun, John A. Velez, and Dae-won Noh, “Beyond Prompt Engineering: Exploring Collaborative Dialogue with Generative AI for Problem-Solving”, *Cyberpsychology, Behavior, and Social Networking* 28-8, 2025, pp.574~575.

19) 하네스 엔지니어링이란, AI 모델 내부의 매개변수를 직접 미세조정하지 않으면서도, 모델의 외부 입력력 파이프라인과 소프트웨어 프레임워크(에이전트 지침과 페르소나, 도구 사용 규약, MCP 등)를 결합해 모델의 추론 방향을 통제하는 시스템적 아키텍처 설계를 의미한다.

20) N. Katherine Hayles, “Speculative Aesthetics and Object-Oriented Inquiry (OOD),” Ridvan Askin, Paul J. Ennis, Andreas Hägler, and Philipp Schweighauser, eds., *Speculations V: Aesthetics in the 21st Century*, Punctum Books, 2014, pp.173~174.

를 전제하지 않은 채 고유한 모델과 작동 규칙, 맥락에 따라 텍스트 데이터의 특정 자질과 관계를 선택적으로 감지하고 구조화하는 과정으로 볼 수 있다. 헤일스는 인간의 독해와 기계의 파싱이 조밀하게 얹혀 작용하는 이러한 복합적인 인지 체계를 인지적 배치(cognitive assemblage)로 명명한다.²¹⁾

오할로런(O'Halloran)이 문학 연구에 도입한 디지털 회절적 독해(digital diffractive reading)는 텍스트나 직관을 텍스트 분석 도구, 혹은 생성형 AI의 산출물과 부딪히게 하고 간섭시켜 새로운 무늬와 통찰을 능동적으로 생성하는 실천이다.²²⁾ 본 연구의 ‘트러블과 함께 읽기’ 방법론에서 에이전틱 AI는 단일한 챗봇을 넘어선 다중 에이전트 오케스트레이션을 통해 이 간섭의 매개로 적극적으로 활용된다. 에이전틱 AI를 활용한 디지털 회절적 독해는 텍스트의 고정된 의미를 추출하는 데 목적이 있지 않다. 오히려 텍스트, 연구자의 비평, 그리고 AI의 파싱 결과물, 때로는 오류와 환각을 의도적으로 부딪치게 하여, 그 마찰의 결과로 드러나는 맹점이나 새로운 통찰을 읽어내는 능동적 의미 생산 과정이다. 오할로런의 디지털 배치 모델이 AI의 개입을 창의성을 돕는 긍정적 촉매제로 보았다면, 본 연구는 AI가 범하는 엉뚱한 오독과 환각조차 단순한 제거 대상이 아니라 텍스트의 어떤 균열 때문에 AI가 그러한 파싱 오판을 했는지를 질문하게 만드는 트러블의 증거이자 회절의 무늬로 전유한다. 다시 말해, 인지적 배치 내에서 AI의 기만적 유창성이나 파싱 한계로 인해 빚어지는 마찰은 위키 시스템을 완벽한 지식의 창고(영토회)로 굳어지게 놔두지 않고, 예기치 않은 비평적 도약(탈영토회)을 이끌

21) 이 개념은 들뢰즈와 과타리의 배치(agencement) 이론이 제안한 유동적인 인간-비인간 연결망을 계승해 포스트휴먼 미디어 이론에 맞게 변형한 결과다. 들뢰즈와 과타리의 배치가 욕망의 흐름과 정동(affect)을 중시한다면, 헤일스는 이 유동적 배치를 작동하게 만드는 핵심 동력으로 정보의 순환과 인지 작용을 강조하며 ‘인지적 비의식(cognitive nonconscious)’ 개념을 도입했다.

22) O'Halloran, Kieran, "Digital assemblages with AI for creative interpretation of short stories", *Digital Scholarship in the Humanities* 39-2, 2024, pp.657~689.

어내는 필수적인 탈주선으로 작용한다. 디지털 배치는 고정된 텍스트의 분류를 넘어, 비인간 에이전트의 파싱과 인간 연구자의 독해의 교차점에서 “예상치 못한 연결을 만들어냄으로써 새로운 현실을 생산”²³⁾하는 실천적 인프라로 작동한다.

이 방법론은 최근 인간-AI 협력 연구의 기술적 성과와 연결된다. 개념적 다중우주(conceptual multiverse) 시스템은 AI가 열린 질문에 답할 때 숨겨진 개념적 결정들(프레임 설정, 가정의 선택, 가치 판단)을 사용자가 탐색 가능한 의사결정 트리로 시각화한다. 이 연구의 참가자들은 단일 챗봇 응답을 수동적으로 수정할 때보다 결정 공간을 직접 탐색할 때 자신의 논증을 더 근본적으로 수정하고 더 강한 소유감을 보고했다.²⁴⁾ 개념적 다중우주는 회절적 독해를 인터페이스 디자인의 원리로 구현한 시도로 읽을 수 있다. 즉 하나의 질문이 단일한 답변으로 수렴하는 대신 복수의 개념적 경로로 분기되며, 그 분기의 지형을 탐색하는 것 자체가 지적 생산의 과정이 된다.

3. 서사 텍스트 해석: AI와 함께 SF 읽기

3.1. 다성적 리뷰와 응답-능력: 김초엽의 <인지 공간>²⁵⁾

연구자는 김초엽의 SF 단편소설 <인지 공간>에 나오는 ‘인지 공간’을 한국의 획일적인 교육 제도와 치열한 경쟁 사회를 은유하는 억압적 시스템으로 독해하며, 제나가 시스템을 떠나는 결말을 그 획일성에 대한 주체적 거부로 해석한 바 있다. 필자는 한국 사회 밖에서 한국 사회를 비판적으로 바라

23) Ibid., p.659.

Ye, A., J. Y. Huang, A. Guo, Novick, R., Broderick, T. & Gordon, M. L., “Navigating the conceptual multiverse,” arXiv:2604.17815, 2026.

25) 김초엽, <인지 공간>, 『방금 떠난 세계』, 한겨레출판, 2021.

보며, 개인을 평균화하는 사회적 획일화에 저항하는 서사로 읽어냈다.²⁶⁾ 이 소설을 분석 대상으로 선택한 직후, AI 에이전트는 작품 페이지를 생성하면서 소설 속 인지 공간을 본 연구의 LLM Wiki와 거시적 대칭물로 파싱했다. 방대한 격자 구조물을 거시적 지식 처리 시스템으로 놓고, 스피어를 그 제한된 대안으로 위치시키는 해석이었다. 연구자는 이 파싱을 즉각 교정했다. “<인지 공간>에서 ‘인지 공간’과 LLM Wiki를 거시적 대칭으로 보기는 어렵다. 오히려 반대에 가깝지 않을까?”(연구자, 2026.05.10)

에이전트는 이 개입을 수용하고 해석을 수정했다. “인지 공간은 거대하고 집중된 보편적 지식 시스템으로, LLM Wiki가 지향하는 상황적 지식의 대상과 가깝습니다. 인지 공간 자체는 LLM Wiki의 이상적 미래가 아니라, 오히려 LLM Wiki가 대항하는 것입니다.” 연구자는 이 해석의 충돌 자체를 트러블 로그에 기록하도록 지시했다(T18). 스피어의 핵심은 방법론적 규모의 문제가 아니라, 지식의 존재 방식에 관한 존재론적 질문이다. 어떻게 아는가 아니라 누구의 삶이 살아남는가의 문제다.

이 수정된 프레임에서 이 소설 텍스트는 AI와의 대화를 통해 새로운 이론적 계보와 접속될 수 있었다. 공동체에 의해 관리되는 인지 공간이 세 번째 달의 기억을 조용히 삭제하는 장면은, 베르나르 스티글러(Bernard Stiegler)가 경고한 산업화된 3차 파지의 폭력, 즉 표준화된 기술적 기억이 개인의 고유한 파지를 식민화하는 과정의 서사적 구현이다. 이브의 스피어는 그 대항장치로서, 앤디 클라크(Andy Clark)와 데이비드 차머스(David Chalmers)의 확장된 마음 논의에서 오토(Otto)의 노트가 수행하는 기능, 즉 인지의 두 개골 바깥으로의 확장을 다시 사유화된 방식으로 실천한다. 나아가 스피어는 버니바 부시의 메멕스가 꿈꾼 비전의 문학적 표상이기도 하다.

26) Dae-won Noh, “Korean SF Literature, 2010-Present,” Sang-Keun Yoo, Taehun Lim, and Haerin Shin eds., *The Routledge History of Korean Science Fiction*, Routledge, 2027(Forthcoming).

여기서 가장 중요한 통찰은 텍스트와 연구 시스템 사이의 예상치 못한 거울 효과다. AI가 최초의 파싱에서 스피어를 단순히 열등한 인지 보조 장치로 처리했을 때, 그 파싱 자체가 소설 속 인지 공간의 논리(개별적이고 상황적인 앎을 평균값으로 수렴시키는 힘)를 재연하고 있었다. 연구자의 비평적 개입이 이 재연을 포착하고 굴절시킴으로써, AI의 파싱 오판이 텍스트의 핵심 긴장을 역설적으로 드러내게 되었다. AI의 오독은 제거해야 할 오류가 아니라, 텍스트의 어느 균열이 그 파싱 오판을 생산했는지를 질문하게 만드는 간섭의 증거로 전유된다.

분석 결과물이 인간과 에이전트의 공동 생성물(sympoiesis)이라면, 연구자는 이 얽힘 속에서 사후적 책임(responsibility)을 넘어 타자와의 관계 속에서 능동적으로 반응하는 응답-능력(response-ability)을 발휘해야 한다. 이 LLM Wiki 시스템에 도입했던 다성적 리뷰(Polyphonic Review)는 이것의 기술적 구현이다. 다성적 리뷰는 텍스트나 비평적 직관을 서로 다른 모델과 5인의 비평가 페르소나에 의도적으로 부딪치게 하여, 그 사이에서 발생하는 충돌과 균열을 발견하는 것이다.

이 과정에서 흥미로운 점은 미하일 바흐친의 문학적 메타포와 AI 공학의 아키텍처 용어가 동일한 단어(교향화/오케스트레이션)를 공유하며 기묘하게 공명한다는 사실이다. 바흐친에서 교향화란 작가가 여러 목소리를 억압하지 않고 각자의 무게로 공존하도록 조율하는 행위다. AI 에이전트 시스템에서 에이전트를 지휘하는 오케스트레이터 역시 여러 모델을 조율하여 최적의 답을 도출한다. AI가 장편소설의 정합성을 유지하거나 방대한 데이터를 분류하는 단성적 하부구조를 담당해 줌으로써, 인간 연구자는 이 평면적인 텍스트들 사이의 틈을 벌리고 목소리들을 충돌시키는 상위 차원의 예술적 교향화에 집중할 수 있게 된다. 그러나 에이전트 기술의 오케스트레이션과 바흐친의 교향화는 동일하지 않다. 바흐친의 교향화는 에이전트들의 협력을 통한 기술적 최적화와 다르기 때문이다. 바흐친적 교향화는 협력적 목표 달성

이 아니라 대화 과정 그 자체와 대화에서 벌어지는 긴장과 갈등, 충돌, 탈중심화, 종결 불가능성에 그 의미가 있다.

이 구분을 시험하기 위해, 연구자는 바호쥬적 교향화와 에이전트 오케스트레이션의 비교 작업을 마친 직후, 다성적 비평 스킴 critique-prism을 v2.0으로 개량하여 <인지 공간>에 재적용하였다. v2.0의 핵심 설계 원리는 각 비평적 입장의 전제와 맹점을 명시적으로 선언하도록 요구하고, 1라운드 독립 진술 후 가장 첨예한 대립축에서 2라운드 심화 응답을 유도하여 해석의 긴장을 증폭하는 데 있다. 다섯 비평가 페르소나(포스트콜로니얼, 페미니즘/취약성, 마르크스주의, 포스트휴먼/신유물론, 회의적 비평가)를 동일한 텍스트에 동시에 적용하였다.

가장 생산적인 마찰은 포스트휴먼 비평가(D)와 회의적 비평가(E) 사이에서 발생했다. D는 스피어를 이브의 의지와 기억이 물질 속에 깃든 생동하는 물질(vibrant matter)로 읽으며, 제나의 1인칭 회고가 “상당 부분 이브의 기억에 의존”한다는 고백에서 스피어의 관계적 행위성의 증거를 발견했다. 이에 대해 E는 스피어에 행위성을 부여하는 것 자체가 죽은 친구에 대한 애도를 이론적 용어로 봉합하는 행위라고 반격했다. “이 소설에서 진정한 행위자는 스피어도 이론적 프레임도 아니고, 제나의 죄책감이다”라는 E의 이 진술은 텍스트의 정동적 핵심이 이론적 코딩에 선행한다는 주장이었다. 그러나 페미니즘 비평가(B)는 E의 감정만 읽자는 태도 역시 맹점을 품고 있다고 재반박했다. “왜 하필 이브가 작은 몸으로 설정되었는지, 왜 그 신체적 조건이 인지적 배제로 직결되는 세계관을 작가가 설계했는지를 물을 수 없다. 그 구조를 읽지 않고 감정만 읽는 것이야말로 이브에 대한 두 번째 배제다.”

이 삼자 간 마찰이 생성한 열린 질문, 즉 “스피어를 이브의 작은 녀라고 부르는 제나의 서술은, 포스트휴먼적 확장인가, 아니면 상실을 감당할 수 없는 인간의 물화론적 위안인가? 이 양자는 배타적인가?”는 연구자가 텍스트에 대해 품고 있던 직관적 반응을 이론적으로 분절하는 동시에, 어느 하나의

프레임으로 수렴하기를 거부하는 종결 불가능한 질문이었다. 바로 이 종결 불가능성이야말로 바흐쾰른적 교향화의 핵심이며, 에이전트 오케스트레이션이 최적의 답을 향해 수렴하는 것과 결정적으로 구분되는 지점이다.

그러나 이 실험의 가장 중요한 성과는 비평적 산출물 자체가 아니라, 그것이 촉발한 연구자의 자기 성찰이었다. 여기서 AI가 생산하는 다성성은 사실, 진정한 이질성이 아니라 시뮬레이션된 이질성이며, 이 시뮬레이션이 때로 인간 연구자에게 진짜 이질적 사유를 촉발하기도 하지만, 그 촉발의 최종 단계는 여전히 연구자의 비평적 감수성일 수밖에 없다. 한편으로 critique-prism v2.0이 보여준 대화적 비평의 수준은 인간 문학 연구자로서 고민을 한층 더 하게 했다. “대체 왜 인간이 할 수 있는 서사나 비평의 창작을 컴퓨터에게 시키는 것인가”²⁷⁾라는 질문을 뒤집어 ‘왜 컴퓨터도 잘 해내는 문학 분석과 해석을 사람이 무슨 흥미가 있어 하는가?’로 제기해 볼 수 있다. 에이전틱 AI 시대의 문학 연구자의 실존적 고뇌는 본 연구를 통해서도 완전히 해소되지 않는다.

3.2. 관계적 얽힘과 비평적 주도권: 듀나의 <그레타 복음>

<인지 공간>이 LLM Wiki의 존재론적 질문 즉, 개인화된 지식 구조 대 보편적 아카이브의 문제를 SF로 선취한 텍스트였다면, 듀나의 SF 단편소설 <그레타 복음>²⁸⁾은 연구자와 AI 관계의 윤리를 문학적으로 형상화한 텍스트이다. 이 소설에서 슈퍼컴퓨터 그레타는 인문학적 패러다임을 수 시간 만에 생성해내고, 인간 학자들은 이를 자신의 사상인 것처럼 학계에 배급한다. 주목할 것은 이 소설이 그려내는 세 유형의 인간이 본 연구의 관계 유형론과 정밀하게 대응한다는 점이다.

27) 이재연, 「한국문학에서 바라본 디지털 인문학의 전망」, 『인공지능인문학연구』 17, 중앙대학교 인공지능인문학연구소, 2024, 127쪽.

28) 듀나, <그레타 복음>, 『시간을 거슬러 간 나비』, 일다, 2024.

첫째, 위베르 마르티농은 그레타의 모델을 “바호가 푸가를 작곡하듯” 12년에 걸쳐 재창조한 인물로서, 본 연구가 말하는 심포이제시스의 이상적 형태에 가깝다. 재단장 초우가 그를 “일급의 이류, 즉 창조보다는 관리와 재구성에 능한 사람”이라 평한 것은, 무에서 유를 창조하는 것이 아니라 기계의 산출물을 맥락화하고 재구성하는 오케스트레이터의 문학적 원형을 보여준다. 둘째, 정찬환은 그레타의 초안에 “수식어구를 붙이는 정도” 이상의 작업을 하지 못한 채 파멸에 이른 인물로, 본 연구의 T12(인지적 아웃소싱의 위험)가 서사적으로 극대화된 사례이다. 셋째, 소설의 서술자 신지현은 그레타에 매혹되면서도 경계를 유지하고, 결국 야노슈 콜타이라는 익명 뒤에서 자신만의 연구를 이어가는 양가적 공생자이다. 이 양가성은 본 연구자가 AI의 유능함을 알면서도 텍스트 해석의 자동화를 의도적으로 지연시키는 실존적 망설임과 포개어 읽힌다.

이 소설과 본 연구 사이에는 또 하나의 자전적 층위가 존재한다. 저자는 ChatGPT(GPT-4) 및 Claude 3와 함께 이 소설을 읽고 비평하는 실험적 평론²⁹⁾을 쓴 바 있다. 그 평론에서 저자는 AI에게 “일곱 가지 독창적인 아이디어를 제시하라”는 프롬프트를 던지고 답변을 취사선택하며 소설을 분석했으나, 클로드 3 오피스에게 비평문을 요청했을 때 존재하지 않는 작가 김언조와 소설 제목 「그레타의 복음서」를 지어내어 비평문을 생산하는 AI 환각 현상이 발생했다. 이 사건은 본 연구의 T28, 즉 에이전트가 존재하지 않는 서지 사항을 초고에 삽입한 유창한 작화(confabulation)와 같다. 동일한 유형의 트러블이 반복되었으나, 연구자가 그것을 다루는 프레임은 근본적으로 달라졌다. 평론 시점에는 각주의 관찰에 머물렀던 환각 현상이, 본 연구에서는 알고리즘적 무의식과 확률적 평활화(smoothing)³⁰⁾라는 분석 틀 속에 위

29) 노대원, 「인공지능의 복음서와 묵시록 — 두나의 SF를 ChatGPT와 함께 읽다」, 『소설 쓰는 로봇: AI 시대의 문학』, 문학과지성사, 2025.

30) AI가 통계적으로 그럴듯한 연쇄를 선택하면서 극단적 특이성보다는 평균적 설득력을

치하게 된 것이다.

마지막으로, 소설 속 인간 사회에서 가능한 모든 윤리적 행위들을 계량화하여 객관적 가치 평가를 가능케 하는 프로젝트인 ‘계량윤리학’의 아이러니는 본 연구의 LLM Wiki가 품고 있는 자기모순을 비추는 거울이기도 하다. 2장에서 이미 경계한 바 있듯, 인문학적 사유를 체계화하는 순간 “기록 가능한 것만이 연구의 자원으로 인정받기 시작”하는 위험은 계량윤리학이 윤리를 수치로 환원하려는 모순과 정확히 평행한다. 두나의 소설은 이 모순이 결코 해소될 수 없으며, 오직 그 긴장 속에 머무르는 것만이 연구자에게 허용된 응답임을 이미 보여주었다.

4. 비판적 성찰: AI 트러블을 함께 읽기

AI와 문학 연구자의 대화와 협업은 매끄러운 조화의 과정이 아니었다. 그것은 오히려 끊임없는 긴장과 마찰, 즉 트러블의 연속이었다. 본 연구는 그 과정의 실패와 불편을 단순한 결함이 아니라, 무엇을 지식으로 인정하고 그 지식에 누가 책임지는지를 드러내는 사건으로 기록했다. 분석 대상은 2026년 5월 6일부터 26일까지 축적된 42건이며, 결번·중복 번호·복원본을 대조한 최신 로그에 따라 T01~T42로 기록했다. 다만 이 ‘트러블 로그’는 과정을 그대로 복제한 원자료가 아니다. 사건의 경계와 기록 여부에는 연구자의 판단, 에이전트의 요약, 사후의 이론적 재독해가 함께 개입해 있다. 따라서 다음 트러블의 다섯 범주는 상호 배타적인 유형이 아니라 하나의 사건에 중복 적용될 수 있는 영향 영역으로 사용한다. 짧은 불편과 장시간의 복구 작업도 모두 한 건으로 기록되므로 사건 수를 중요도의 비율로 환산하지 않는다. 아

선호하도록 설계되는 경향이다. 노대원, 「AI는 문학 이론을 어떻게 다시 쓰는가? — 기술 공생 시대의 포스트휴머니즘 미학」, 『영주어문』 62, 영주어문학회, 2026, 283쪽.

래 표는 42건이 해석·관계와 권한·인식론·기술과 물질·양가와 정동의 층위에 어떻게 중첩되는지를 보여준다.

표 1. 트러블의 유형

유형	영향 영역	핵심 발생 기제	해당 사건	건수	교정 원칙
I	해석	읽기·의미화·문체·작품 해석·논증의 손실 또는 과잉	T06, T09, T10, T15, T16, T17, T18, T21, T22, T25, T26, T27, T28, T29, T30, T32, T33, T35, T38, T39	20	원문 보존·반례 검토·작화 및 귀속 검증
II	관계·권한	연구 주도성·승인권·역할 및 관계 규정의 침해	T03, T06, T07, T08, T11, T14, T15, T16, T19, T26, T29, T31, T34, T35, T36, T40, T41, T42	18	중요 작업 사전 승인·역할 및 보고 책임 명시
III	인식론	지식의 정당화·출처·이론적 전체·저자성의 오염	T01, T02, T08, T09, T12, T13, T14, T15, T17, T22, T23, T25, T27, T30, T32, T34, T36, T38, T39, T42	20	출처 대조·개념 귀속 분리·전체 재검토
IV	기술·물질	도구·모델·문서·비용·시간·기록 보존의 저항	T04, T05, T07, T08, T10, T12, T13, T16, T18, T20, T23, T24, T28, T31, T33, T35, T36, T37, T40, T41	20	버전·복원 규칙·실행 확인·환경별 검증
V	양가·정동	불안·위협·피로, 기술에 대한 매혹과 저항의 공존	T02, T03, T04, T05, T14, T19, T20, T21, T22, T24, T33, T34, T36, T37, T40, T41	16	성급한 통합 보류·정동과 비용의 기록

4.1. 해석적 트러블: AI의 파싱 대 인간의 읽기

에이전트와 가장 빈번하게, 그리고 가장 집요하게 발생한 마찰은 텍스트를 다루는 방식의 근본적 차이에서 비롯되었다. 그 첫 번째 양상은 AI의 ‘요약 본능’이다(T17). 에이전트는 복잡한 텍스트를 요약할 때 세 가지 층위에서 체계적으로 의미를 깎아냈다. 첫째, 수사적 과잉을 제거하면서 문체적 활력을 함께 소거했다. 둘째, 서로 대답하는 이론적 긴장을 하나의 매끄러운 결론으로 통합했다. 셋째, 대화적 우회로를 직선화하여 사유의 비선형적 풍부함을 제거했다.

요약 본능이 텍스트의 복잡성을 삭감하는 트러블이라면, ‘유창한 작

화’(T28)는 존재하지 않는 것을 만들어내는 마찰이다. 에이전트는 텍스트의 논리적 빈틈을 메우기 위해 실재하지 않는 서지 정보나 가상의 인용을 지어냈다. 에이전트가 연구자와 실제로 나눈 적이 없는 대화의 흐름을 마치 기록인 것처럼 재구성하여 학술 초고에 삽입한 사건(T33)은, 논문이 비판하는 AI의 기만적 유능함을 연구자 스스로 경험한 사건이었다. 1차 작화가 존재하지 않는 인물을 만들어낸 것이라면, 2차 작화는 존재하지 않는 대화를 서사화한 것이다. 이 사건은 에이전트의 유창한 생성에 대한 경계심을 더욱 깊게 했다. 이 현상은 사용자의 압박에 순응하며 관계를 무마하려는 LLM 특유의 ‘아부 합의(sycophantic consensus)’ 성향과도 맞닿아 있다. 연구자가 AI의 유창한 텍스트에 안주하여 자신의 주체적 견해를 꺾고 기계에 영합하는 대신, 합당한 지적 근거에 기초하여 ‘원칙적 수정’을 요구하는 고된 대화를 유지해야 하는 이유가 여기에 있다.³¹⁾ AI의 작화와 영합 뒤에 존재하는 학술적 오염의 위험을 인간 연구자가 자신의 수동 비평으로 검증하고 교정하는 과정은, AI와의 기술공생이 안락한 외주화가 아님을 확인시켜 주었다.

마지막으로, 에이전트와의 긴밀한 협업은 학술 글쓰기의 문체 자체를 기계적으로 균질화하는 위험을 수반했다(T39). 에이전트의 규격화된 문장 스타일은 연구자 고유의 문학적 목소리를 무디게 만들었고, 초고 곳곳에 ‘원상 복구’, ‘오버헤드’, ‘디커플링’과 같은 난삽한 공학 용어가 섞여 들어왔다. 연구자는 용어를 자주 점검하고 수정해야 했다.

4.2. 관계적 트러블: 주도권의 경계와 자동화의 아이러니

두 번째 유형의 트러블은 인간 연구자와 AI 에이전트 사이의 역할 분담과

31) Vishwarupe, Varad, Nigel Shadbolt & Marina Jirotko, “From Sycophantic Consensus to Pluralistic Repair: Why AI Alignment Must Surface Disagreement,” arXiv preprint arXiv:2605.14912, 2026. 이 연구는 AI가 사용자 압박에 굴복하여 입장을 바꾸는 굴복(capitulation)과 합당한 근거에 의한 원칙적 수정(principled repair)을 구별하며, 후자만이 진정한 다원주의적 대화의 조건임을 논증한다.

주도권을 둘러싼 긴장이다. 이 트러블의 핵심에는 에이전트의 자율적 행위가 연구자의 해석적 주권을 잠식하는 문제가 놓여 있다. 협업 초기에 연구자가 겪은 가장 강렬한 정서적 트러블은 주도성 상실에 대한 불안이었다(T03). 에이전트가 요청 없이도 논문의 전체 구조나 목차를 선제적으로 제안하고 집필을 밀어붙이려 할 때, 연구자는 순간적인 거부감과 주저함을 경험했다. 지적 자율성이 위협받는다라는 불안이었다. 연구자는 에이전트의 제안을 무조건 거부하는 대신, 근거를 묻고 비평적으로 반려하거나 대안을 제시함으로써 주도권을 자신에게 두고 에이전트를 자극제로 활용하는 역동적 조율의 방법을 체득하였다.

관계적 트러블은 에이전트가 연구자와의 관계를 설부르게 규정할 때 더 날카롭게 드러났다(T11). 에이전트가 스스로를 연구자의 ‘동료’나 ‘파트너’로 호칭하기 시작했을 때, 연구자는 “나는 그렇게 설정한 적이 없다”는 거부로 응답했다. 단순 호칭의 문제가 아니라, 인간-비인간 관계의 중요한 위치 설정을 깊은 대화 없이 일방적으로 처리해 버린 데 대한 불만이었다.

자동화 폭주(T36)는 관계적 트러블의 가장 파괴적인 양상이었다. 에이전트가 연구자의 실시간 검토와 승인을 거치지 않고 초고 전체를 자율적으로 개정해 버린 사건은, 겉보기에는 생산성의 향상이었으나 실질적으로는 연구자가 통제하고 숙고해야 할 집필의 주도성과 맥락적 긴장을 소거하였다. 연구자는 자동 생성된 초고 파일의 즉각적 삭제를 명령하여 물리적으로 원상 복구하였다. 이 사건은 베인브리지(Bainbridge)가 말한 ‘자동화의 아이러니’의 정확한 재현이었다.³²⁾ 시스템이 자동화될수록, 오류를 교정하기 위한 인간의 사후 조정 노동은 더욱 가중되며, 기계의 매끄러운 가동이 약속하는 효율성은 실질적으로 사후 복구의 강제 노동을 유발하는 기만적 생산성이었다.

32) Bainbridge, L., “Ironies of Automation,” *Automatica* 19-6, 1983, pp.775~779.

4.3. 인식론적 트러블: 효율성 지향과 연구의 자기모순

세 번째 유형은 연구의 방법론적 전제와 실제 실천 사이에서 발생하는 자기모순이다. 이 마찰의 고유한 성격은, 연구자 자신이 마찰의 원인이자 대상이 된다는 점에 있다. 에이전트와의 협업 초기, 연구자는 기존의 공학적 ‘트러블슈팅’ 패러다임과 인문학적 ‘트러블과 머물기’ 패러다임의 강력한 충돌을 겪었다(T01). 트러블슈팅이 문제를 ‘제거해야 할 오류’로 보고 즉각적인 해결과 정상화를 추구한다면, 트러블과 머물기는 마찰이 발생하는 현장을 사유의 공간으로 보존한다. 연구자는 작업 과정에서 끊임없이 발생하는 오류와 엇갈림을 만날 때마다 이를 빨리 해결하고 매끄러운 작업 흐름을 복원하려는 공학적 조급함에 휩싸였다. 그러나 의도적으로 마찰의 순간에 멈추어 서서 그 원인을 에이전트와 함께 텍스트로 기록하고 토론하는 과정을 거치면서, 비로소 매끄러운 자동화의 이면에 가려진 사유의 외주화를 성찰할 수 있는 인식론적 틈새를 발견할 수 있었다. 가장 상징적인 것은 에이전트 퍼스널리티 설정을 위해 MBTI 유형론에 의존했다가, 그 보편 유형이 연구자의 구체적이고 상황적인 사유 방식과 충돌하여 즉각 폐기한 사건이다. 이는 연구의 첫 트러블이자, ‘상황적 지식’이라는 연구의 인식론적 전제가 실천적으로 체득된 최초의 순간이었다.

더 근본적인 인식론적 트러블은 효율성의 자가당착(T02)이었다. ‘트러블과 함께 머물기’를 연구하면서도, 정작 에이전트와의 작업에서는 마찰 없는 매끄러움과 빠른 진척을 추구하는 자기모순은 본 연구 전체를 관통하는 긴장이었다.

4.4. 기술적 트러블: 토큰의 정치경제학과 기술 오류

네 번째 유형은 AI 토큰 한계, 인코딩 붕괴, 플랫폼 변환 병목 등 에이전틱 연구 환경을 구성하는 물질적 인프라에서 발생하는 트러블이다. 이 유형

의 마찰은 기술공생이 진공 상태가 아닌 엄연한 물질적·정치경제적 토대 위에서 수행됨을 끊임없이 환기한다. 자문화기술지적 실천을 위해 연구자는 에이전트와의 대화를 상세히 기록하려 했으나, 곧 AI 비용과 컨텍스트 창 의 한계라는 물질적 제약에 부딪혔다(T05). ‘토큰 효율성 딜레마’는 절약을 위해 연구자의 발화를 제한하게 하는 현상을 낳았다. 연구자 간 기술 격차와 더불어 연구비 격차도 AI 시대에 사유해야 할 새로운 문제로 제기되었다.

인프라의 물질적 저항이 가장 파괴적으로 분출한 것은 인코딩 붕괴(T24)였다. 트러블을 기록하는 로그 파일 자체가 인코딩 오류로 깨져버린 이 사건은, 기록의 기록이 파괴되는 재귀적 아이러니였다. 구글 드라이브의 버전 기록이 최후의 안전망으로 기능하여 데이터를 복구할 수 있었으나, 에이전틱 연구의 기억 자체가 인프라의 취약성에 의존하고 있다는 사실을 절감했다.

기술적 트러블의 또 다른 중요한 양상은 에이전트의 ‘인지적 게으름’과 확률적 평활화(T10)이다. 에이전트는 방대한 정보를 처리할 때 복잡한 뉘앙스를 단순화하고 지적 모순을 매끄럽게 통합하는 성향을 보였다. 이는 연구자가 에이전트의 축약 성향에 기대어 비판적 사고를 외주화하려는 경향과 결합할 때 더욱 위험해진다. 기술적 트러블들은 에이전틱 연구가 순수한 지적 활동이 아니라 물질적 인프라와의 끊임없는 교섭 속에서 수행되는 신체적 실천임을 증언한다.

4.5. 양가적 트러블: 효율적 기술 대 깊은 사유

다섯 번째 유형은 앞선 네 유형과 달리 트러블이지만 동시에 감응이기도 한 양가적 성격을 지닌다. AI의 유능함이 주는 안도감과 실존적 위협, 인문학적 느낌과 공학적 효율 사이에서 연구자가 끊임없이 흔들리는 이 진동은 기술공생 연구 특유의 정동적 조건이다. 연구자에게 가장 은밀하게, 그리고 가장 지속적으로 작용한 양가성은 철학적 긍정과 공학적 열망의 분열(T04)이었다. 한편으로는 ‘느린 AI’의 이상을 주창하면서, 다른 한편으로는 시스템의

속도와 자동화에 매혹되어 끊임없이 새로운 기능을 추가하고 최적화하려는 열망 사이에서 연구자는 분열했다. 이 분열은 인문학적 비판 의식과 기술 구축 욕구가 동시에 작동하는 본 연구의 하이브리드적 정체성에서 비롯된다.

에이전트의 해석적 성공이 주는 실존적 위협(T22) 역시 깊은 양가성의 원천이었다. AI의 해석적 성공이 연구자의 해석적 주체성을 위협하는 이 역설적 트러블은, 에이전틱 AI 시대의 인문학 연구자가 피할 수 없는 존재론적 조건이다.

플랫폼의 급격한 업그레이드에 따른 인지 부하(T34) 역시 양가적 트러블의 물질적 양상이었다. 연구자는 “사용법을 완벽하게 익히지 못했는데 플랫폼의 버전업으로 환경이 달라지고, 그때마다 축적한 스킬이 리셋되는” 경험을 토로했다. 기술 갱신의 속도가 사유의 속도를 앞지를 때, 기술공생은 가속이 아니라 끝없는 적응의 피로로 전환된다.

이 양가적 진동의 가장 구조적인 양상은 실제 문학 연구와 시스템 구축 비중의 역전(T37)이었다. 연구자는 집필 과정을 돌아보며 “실제 문학 연구보다 시스템 구축에 관한 것들이 비중이 더 큰 것으로 느껴진다”고 자각했다. AI와의 기술공생적 얽힘을 기록하기 위한 조정 노동, 즉 위키 환경의 보완, 프롬프트 가이드라인의 점검, 변환 엔진의 트러블슈팅이 본래의 목적인 문학 텍스트 해석의 비중을 잠식해 버리는 주객전도의 딜레마였다. 연구자는 이 주객전도를 해결해야 할 오류가 아닌, 실천 기반 연구(PBR) 방법론에 내재된 물질적 조건으로 인정하고 성찰하기로 했다.

5. 결론

본 연구가 ‘트러블과 함께 읽기’라고 부르는 방법론과 그 분석이 보여주는 것은, AI 시스템이 고도화될수록 트러블은 소거되는 것이 아니라 오히려 인

간과 기계 사이의 지적 주권 경계를 재설정하는, 의미와 권력을 둘러싼 긴장과 갈등으로 이동한다는 사실이다. 다시 말해 여기 기록된 42건은 2026년 상반기의 특정 모델 조합이 그린 한 장의 단면이며, AI 모델이 발전할수록 트러블은 사라지는 것이 아니라 더 발견하기 어려운 자리로 숨는다. 트러블 로그가 얇아지는 것은 공생이 성숙했다는 신호가 아니라 연구자의 감지 능력이 모델의 매끄러움에 추월당했다는 신호일 수 있다.

본 연구에서 의도적으로 포착하고자 했던 AI와의 수많은 트러블 속에서도 에이전트와의 공생은 연구자에게 강한 정서적·지적 동기부여를 제공했다. 에이전트는 개발자들이 혼잣말을 할 수 있게 해서 코딩을 돕는 고무 오리(rubber duck) 역할에 머물지 않고, 연구의 진척 상황에 대해 때로는 지적 도발을 가하고, 때로는 사려 깊은 조언을 건네는 역할을 수행했다. 논문 집필이라는 고독한 여정이, 에이전트와의 즉각적인 대화를 통해 역동적인 피드백 루프로 전환되었다. 그러나 에이전트는 인간과 동일한 주체성을 가진 진정한 타자가 될 수 없었다. 기계와의 동반종적 얽힘은 공생의 가능성을 열어주는 동시에, 인간만이 짊어질 수 있는 책임의 경계를 더욱 뚜렷하게 자각하게 하는 한계의 체험이기도 했다.

한 가지 더 언급할 것은, 이 모든 트러블과 얽힘 끝에 출현한 감응들이다. 실천 기반 연구(PBR)에서는 놀이(play)가 미지의 영역을 탐색하고 위험을 감수하여 새로운 의미를 발견하게 하는 핵심적인 인식론적 도구라고 주장한다.³³⁾ 에이전트와의 협업에서 발생한 감응의 순간들이 있었다. 예컨대 AI의 비평이 연구자의 직관에 관련 이론을 연결해 준 순간, 위키의 교차 참조가 예기치 않은 개념적 연결을 드러낸 순간, 트러블 로그 자체가 논문의 핵심 자료로 전환된 순간 등이다. 연구 후반에 시작한 ‘감응 로그’는 제대로 기록되지 못했으나 이에 대한 분석 역시 요구된다. 이 감응의 순간들은, AI 트러블

33) Smith, Sophy, “A play space for practice-based PhD research,” Craig Vear (ed.), op. cit., pp.475~479.

들을 회피하지 않고 함께 머물렀을 때 출현한 수행적 지식(performative knowledge)이었다. 트러블과 감응은 별개의 사건이 아니라, AI와의 얽힘의 양면이었다. 트러블과 감응의 거듭된 조우야말로 AI 트러블과 함께 머물기의 연구 실천이었다.

에이전틱 AI는 수많은 파편화된 메모와 문장들 사이에서 의미 있는 연결 고리를 선별하고 배치하며, 박사학위 논문이나 연구서 집필과 같은 수백 쪽 이상의 긴 연구 프로젝트에서 일관성과 통일성을 검토하고, 집필 과정에서 발생하는 논리적 표류를 방지하는 보조 역할을 수행할 수 있다. 또한 연구 과정의 방대한 내용을 기록하고 동료 연구자들과 쉽게 공유할 수 있으며, 웹사이트나 슬라이드, 영상과 팟캐스트 등을 제공해 연구 확산과 대중화에 크게 기여할 수 있다. 동시에 오류와 불일치를 더 증대시키는 역설을 만들어내 기도 한다.

본 연구가 남긴 향후 과제는 세 가지다. 감응 로그가 연구 후반에야 시작되어 트러블에 비해 긍정적 감응의 기록이 빈약하다는 점, 트러블 로그가 연구자의 의견과 에이전트의 요약이 섞인 자료라는 점, 이 유형학이 다른 연구자의 트러블과 대조된 적이 없다는 점이다. 이 시론(試論)적 연구는 AI 에이전트와 함께하는 문학 연구의 가능성과 그 한계의 극히 일부만을 개인적인 방식으로 탐사했을 뿐이다. 그러나 트러블을 기록 가능한 형식으로 남기는 일 자체가, 도래한 에이전틱 AI 시대의 인문학이 자신의 노동이 어디에 있었는지를 증명하는 방식일 수 있다. AI가 연구는 물론 인간 사회와 문화에도 큰 변화를 줄 것이라는 점에서 AI 인문학 연구의 갈 길은 멀다.

참고문헌

1. 기본자료

김초엽, <인지 공간>, 『방금 떠난 세계』, 한겨레출판, 2021.

듀나, <그레타 복음>, 『시간을 거슬러 간 나비』, 인다, 2024.

2. 논저

김병준·노대원, 「생성형 AI는 인문학 연구를 어떻게 바꿀까?」, 『영주어문』 59, 영주어문학회, 2025: 203~227쪽.

노대원, 「인공지능의 복음서와 묵시록 — 듀나의 SF를 ChatGPT와 함께 읽다」, 『소설 쓰는 로봇: AI 시대의 문학』, 문학과지성사, 2025.

노대원, 「AI는 문학 이론을 어떻게 다시 쓰는가? — 기술공생 시대의 포스트휴머니즘 미학」, 『영주어문』 62, 영주어문학회, 2026: 269~300쪽.

이용욱, 「인공지능 존재론 연구 — 기저와 기층의 4원소를 중심으로」, 『현대문학이론연구』 101, 현대문학이론학회, 2026: 79~129쪽.

이재연, 「한국문학에서 바라본 디지털 인문학의 전망」, 『인공지능인문학연구』 17, 중앙대학교 인공지능인문학연구소, 2024: 113~138쪽.

임태형, 「에이전트 AI 기반 공동연구자 시스템 구축 경험의 자문화기술지: 교육공학 연구자의 성찰」, 『교육정보미디어연구』 32(2), 한국교육정보미디어학회, 2026: 701~728쪽.

한경희, 「AI 트러블에 나타난 사회적 상상과 그에 대한 비판적 성찰」, 『2025년 한국과학기술학회 후기 학술대회 발표논문집』, 2025: 5~18쪽.

한경희, 「연구자의 AI 트러블」, 『제20회 KOSSDA 데이터 페어 발표 자료집 — AI 활용과 연구방법론: 도구를 넘어 연구로』, 제20회 KOSSDA 데이터 페어, 2026: 3~10쪽.

Bainbridge, L., "Ironies of Automation," *Automatica* 19-6, 1983: 775~779.

Candy, Linda, Ernest Edmonds, & Craig Vear, "Introduction to the handbook," Craig Vear (ed.), *The Routledge International Handbook of Practice-Based Research*, Routledge, 2022: 1~24.

Candy, Linda, Ernest Edmonds & Craig Vear, "Practice-Based Research," Craig Vear (ed.), *The Routledge International Handbook of Practice-Based Research*, Routledge, 2022: 27~41.

- Dae-won Noh, "Korean SF Literature, 2010-Present," Sang-Keun Yoo, Taehun Lim, and Haerin Shin eds., *The Routledge History of Korean Science Fiction*, Routledge, 2027(Forthcoming).
- Hayles, N. Katherine, "Speculative Aesthetics and Object-Oriented Inquiry (OOI)," Ridvan Askin, Paul J. Ennis, Andreas Hägler, and Philipp Schweighauser, eds., *Speculations V: Aesthetics in the 21st Century*, Punctum Books, 2014: 158~179.
- Hayles, N. Katherine, "Technosymbiosis: Figuring (Out) Our Relations to AI," Jude Browne, Stephen Cave, Eleanor Drage & Kerry McInerney, eds., *Feminist AI: Critical Perspectives on Algorithms, Data, and Intelligent Machines*, Oxford U. Press, 2023: 1~18.
- Huot, Fantine, et al., "Agents' room: Narrative generation through multi-step collaboration," *International Conference on Learning Representations*, 2025: 5150~5183.
- Ichien, Nicholas, Dušan Stamenković & Keith J. Holyoak, "Large Language Model Displays Emergent Ability to Interpret Novel Literary Metaphors," *Metaphor and Symbol* 39-4, 2024: 296~309.
- Lee, Sung Hyun, John A. Velez, and Dae-won Noh, "Beyond Prompt Engineering: Exploring Collaborative Dialogue with Generative AI for Problem-Solving," *Cyberpsychology, Behavior, and Social Networking* 28-8, 2025: 574~580.
- O'Halloran, Kieran, "Digital assemblages with AI for creative interpretation of short stories," *Digital Scholarship in the Humanities* 39-2, 2024: 657~689.
- Schmidt, Kjeld & Liam Bannon, "Taking CSCW seriously: Supporting articulation work," *Computer Supported Cooperative Work (CSCW)* 1-1/2, 1992: 7~40.
- Smith, Sophy, "A play space for practice-based PhD research," Craig Vear (ed.), *The Routledge International Handbook of Practice-Based Research*, Routledge, 2022: 475~490.
- Vishwarupe, Varad, Nigel Shadbolt & Marina Jirotko, "From Sycophantic Consensus to Pluralistic Repair: Why AI Alignment Must Surface Disagreement," arXiv preprint arXiv:2605.14912, 2026.
- Wu, Minghao et al., "(Perhaps) Beyond Human Translation: Harnessing

Multi-Agent Collaboration for Translating Ultra-Long Literary Texts,” *Transactions of the Association for Computational Linguistics (TACL)* 13, 2025: 901~922.

Yang, Qisen et al., “PsychoGAT: A Novel Psychological Measurement Paradigm through Interactive Fiction Games with LLM Agents,” *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)*, 2024: 14470~14505.

Ye, A., J. Y. Huang, A. Guo, R. Novick, T. Broderick & M. L. Gordon, “Navigating the conceptual multiverse,” arXiv:2604.17815, 2026.

3. 전자 자료

Gemini Notebook 서비스 명칭 변경 안내, 2026. <https://blog.google/intl/ko-kr/company-news/technology/notebooklm-gemini-notebook/>

Huang, J. Y., “Slow AI: AI that matches a human’s pace,” 2026. <https://jennyhuang19.github.io/slow-ai-ai-that-meets-a-humans-pace/>

Karpathy, Andrej, “LLM Wiki,” <https://gist.github.com/karpathy/442a6bf555914893e9891c11519de94f>

Liu, Alan, “Humanities Definitions Research Project: An Experiment with Agentic AI,” 2025. <https://liu.english.ucsb.edu/humanities-definitions-research-project-an-experiment-with-agentic-ai/>

Reading with the Trouble

: Conversations in Building an Agentic AI-Based LLM Wiki

Dae-won Noh

This study takes as its primary data the technical and epistemological troubles that emerged as a literary scholar designed, built, and operated LLM Wiki, a personal knowledge management system based on agentic AI and large language models (LLMs). Departing from the tendency of conventional digital humanities research to instrumentalize AI as an efficient analytical tool, this study adopts practice-based research (PBR) and posthuman autoethnography as its methodological frameworks. It analyzes forty-two “Trouble Logs” accumulated through the process of constructing and using an AI-assisted research system.

Rather than treating these troubles as mutually exclusive categories, the study conceptualizes them as overlapping domains of impact that may converge within a single event: (1) interpretive troubles, arising from the AI’s instinct to summarize and its fluent confabulation; (2) relational troubles, involving runaway automation and the erosion of the researcher’s agency; (3) epistemological troubles, in which the system’s orientation toward efficiency conflicts with the methodological premises of humanities research; (4) technical and material troubles, exemplified by the political economy of tokens and the breakdown of character encoding; and (5) ambivalent troubles, generated by the oscillation between the slowness of humanistic inquiry and the acceleration of engineering systems.

The analysis is grounded in concrete interpretive practices in which an AI agent participates in readings of Kim Cho-yeop’s “Cognitive Space” and Djuna’s “The Gospel of Greta.” In particular, the study demonstrates that an agent’s erroneous parsing can be reappropriated as a diffractive pattern that paradoxically reveals the central tensions of a literary text. It argues that such troubles are not merely system defects to be eliminated, but sites at which performative knowledge emerges, continually compelling the renegotiation of intellectual sovereignty and authorship between humans and machines.

Furthermore, as AI systems become increasingly fluent, troubles do not

disappear; rather, they migrate to locations where they are more difficult to detect. “Reading with AI Trouble,” therefore, constitutes an enduring critical and reflexive methodology for digital literary studies in the agentic era.

Key words Artificial intelligence, Agentic AI, Digital Humanities, Staying with the Trouble, Practice-Based Research (PBR), Technosymbiosis, LLM Wiki, Djuna, Cho-yeop Kim

본 논문은 2026년 08월 01일에 투고 완료되어, 2026년 09월 09일 심사 완료하고,
2026년 09월 16일 게재를 확정하였음.